

**UNIVERSIDAD DE ANTIOQUIA**  
**FUNDAMENTOS DE DEEP LEARNING**

**PROYECTO DE CURSO - ENTREGA 1-**  
**Google Smartphone Decimeter Challenge 2022**

**MANUELA GUTIÉRREZ CANO, 1037657256**  
**SANTIAGO MOLINA ECHEVERRI, 1040752065**  
**WILLIAM ALEXANDER TORRES ZAMBRANO, 71784722**

**DOCENTE**  
**RAÚL RAMOS POLLÁN**

**FACULTAD DE INGENIERÍA**  
**INGENIERÍA DE SISTEMAS**  
**MARZO 26 DE 2023**

## 1) Contexto de aplicación

¿Alguna vez te has perdido en el cambio de carril antes de la salida de una autopista? ¿Quiere saber la hora estimada de llegada (ETA) de un carril de viaje compartido en lugar de otros carriles? Estas y otras características útiles requieren servicios precisos de posicionamiento de teléfonos inteligentes. Los modelos de aprendizaje automático pueden mejorar la precisión de los datos del Sistema Global de Navegación por Satélite (GNSS). Con datos más refinados, miles de millones de usuarios de teléfonos Android podrían tener una experiencia de posicionamiento más precisa.

Los conjuntos de chips GNSS proporcionan mediciones sin procesar, que se pueden usar para calcular la posición del teléfono inteligente. Los teléfonos móviles actuales solo ofrecen de 3 a 5 metros de precisión de posicionamiento. Para casos de uso avanzado, los resultados no son lo suficientemente buenos ni confiables. Las obstrucciones urbanas crean las barreras más grandes para la precisión del GPS. Los datos incluyen solo rastros recopilados en carreteras urbanas ligeras y a cielo abierto. Estas autopistas y calles principales son las vías más utilizadas y pondrán a prueba los límites del posicionamiento de los teléfonos inteligentes. El equipo de Android GPS de Google organizó el **Google Smartphone Decimeter Challenge 2022**, una competencia que busca investigación avanzada en la precisión de posicionamiento GNSS de teléfonos inteligentes y ayuda a las personas a navegar mejor por el mundo que les rodea.

El análisis de este problema puede incidir en la manera en que se interpretan los datos más difíciles. Con una mayor precisión de posición a nivel de decímetros, los usuarios móviles pueden obtener una mejor navegación a nivel de carril, caminar/conducir AR, precisión en la agricultura a través de teléfonos e incluso una mayor especificidad en la ubicación de problemas de seguridad vial. También permite una experiencia de navegación más personalizada y afinada. Es posible utilizar técnicas de redes neuronales convolucionales o redes neuronales recurrentes para analizar estos datos GNSS. Los datos proporcionados en el conjunto de datos son medidas GNSS sin procesar de múltiples constelaciones, lo que los hace adecuados para el uso de técnicas de aprendizaje profundo.

Las redes neuronales convolucionales se pueden utilizar para extraer características espaciales y temporales de los datos de sensores, lo que las hace útiles para analizar la información GNSS en tiempo real. Por ejemplo, se pueden utilizar redes convolucionales para identificar patrones en las mediciones GNSS, como la intensidad de la señal, la fase de la portadora y la tasa Doppler. Las redes neuronales recurrentes por su parte, son adecuadas para analizar secuencias de datos, lo que significa que se pueden utilizar para predecir la posición del teléfono en función de los datos de mediciones GNSS previas. Por ejemplo, se puede utilizar una red neuronal recurrente para predecir la ubicación futura del teléfono en función de las mediciones GNSS anteriores. En resumen, tanto las redes neuronales convolucionales como las recurrentes pueden ser útiles para analizar los datos GNSS proporcionados en el conjunto de datos. El enfoque específico dependerá de la tarea que se quiera realizar, como la clasificación de patrones en las mediciones GNSS o la predicción de la posición del teléfono en función de las mediciones GNSS previas.

## 2) Objetivo de machine learning

El objetivo de este proyecto del curso **Fundamentos de Deep Learning** es calcular la ubicación de los teléfonos inteligentes con una resolución de decímetro o incluso centímetro, lo que podría habilitar servicios que requieren precisión a nivel de carril, como la estimación de ETA de carril HOV. Se desarrollará un modelo basado en mediciones de ubicación sin procesar de teléfonos inteligentes Android recopilados en calles urbanas ligeras y a cielo abierto utilizando conjuntos de datos recopilados por el anfitrión. Este trabajo puede ayudar a producir posiciones más precisas, uniendo la conexión entre la información geoespacial del comportamiento humano más preciso e Internet móvil con granularidad mejorada. Como resultado, se podrían construir nuevos métodos de navegación a partir de datos más precisos.

### **3) Dataset: tipo de datos, tamaño (número de datos y tamaño en disco), distribución de las clases**

La competencia sobre la cual desarrollamos este proyecto es la descrita en <https://www.kaggle.com/competitions/smartphone-decimeter-2022/overview/description>, este desafío proporciona datos de una variedad de instrumentos útiles para determinar la posición de un teléfono: señales de satélites GPS, lecturas de acelerómetros, lecturas de giroscopios y más.

- Tamaño de los datos: 22,9GB Tipo: csv, txt, nmea
- La competición proporciona 1168 archivos de los cuales serán utilizados algunos de ellos para este desarrollo de este proyecto.

### **4) Métricas de desempeño (de machine learning y negocio)**

#### ***Métrica de desempeño de machine learning:***

se califican en la media de los errores de distancia de los percentiles 50 y 95. Para cada phoney una vez por segundo, se calcula la distancia horizontal (en metros) entre la latitud/longitud pronosticada y la latitud/longitud real del terreno. Estos errores de distancia forman una distribución a partir de la cual se calculan los errores de percentil 50 y 95 (es decir, el error de percentil 95 es el valor, en metros, para el cual el 95% de los errores de distancia son menores). Luego se promedian los errores de los percentiles 50 y 95 para cada teléfono. Por último, la media de estos valores promediados se calcula en todos los teléfonos del conjunto de prueba.

La métrica de desempeño descrita podría ser adecuada para evaluar el rendimiento de un modelo de posicionamiento GNSS. Esta métrica tiene en cuenta tanto el error de percentil 50 (mediana) como el error de percentil 95 (valor para el cual el 95% de los errores de distancia son menores), lo que proporciona una evaluación completa del rendimiento del modelo en diferentes situaciones. Además, esta métrica tiene en cuenta la distancia horizontal (en metros) entre la latitud/longitud pronosticada y la latitud/longitud real del terreno, lo que es importante para el posicionamiento GNSS, ya que el objetivo principal es determinar la posición geográfica con alta precisión. En general, es importante seleccionar una métrica de desempeño adecuada para el problema en estudio, y en este caso, la métrica propuesta parece ser adecuada para evaluar el rendimiento de un modelo de posicionamiento GNSS en términos de precisión y robustez en diferentes situaciones.

#### ***Métrica de desempeño del negocio:***

La métrica de desempeño del negocio en este caso podría ser la capacidad del modelo de proporcionar una precisión de ubicación de decímetro y centímetro, lo que permitiría habilitar servicios que requieren precisión a nivel de carril, como la estimación de ETA de carril HOV. Por lo tanto, la métrica de desempeño del negocio podría ser la tasa de aciertos del modelo en la predicción de ubicaciones precisas, medida en términos de la cantidad de ubicaciones precisas predichas en comparación con la cantidad total de ubicaciones predichas. Además, el tiempo de inferencia del modelo también podría ser una métrica importante, ya que la precisión de ubicación se necesita en tiempo real para proporcionar servicios de ETA precisos a nivel de carril. La precisión en la determinación de la ubicación de un teléfono móvil con resolución de decímetros o incluso centímetros puede habilitar una serie de servicios y aplicaciones que requieren alta precisión, como la estimación de ETA de carril HOV (High Occupancy Vehicle), lo cual puede mejorar significativamente la eficiencia del tráfico en carreteras congestionadas.

Además, también se pueden utilizar servicios de ubicación precisos para mejorar la navegación de vehículos autónomos y sistemas de transporte público, proporcionar servicios de emergencia más eficaces, permitir aplicaciones de realidad aumentada más precisas y mejorar la seguridad en áreas

donde es importante conocer la ubicación exacta de las personas o los bienes. Por lo tanto, la métrica de desempeño del negocio se centrará en la precisión del modelo en la determinación de la ubicación del teléfono móvil, con el objetivo de lograr una precisión de decímetros o incluso centímetros. Esto permitiría la implementación de aplicaciones y servicios que requieren alta precisión de ubicación, lo que a su vez podría mejorar significativamente la eficiencia, seguridad y comodidad en varios ámbitos, como el transporte, la navegación, la seguridad y la realidad aumentada.

## Trabajo previo

Debido a que actualmente los teléfonos inteligentes ya se encuentran al alcance de la gran mayoría de personas y de que muchos de los aplicativos incluyen servicios que dan uso de la navegación y localización, se reconoció el problema de identificar y reconocer escenarios para la correcta navegación de interiores y exteriores. Para esto se ha utilizado técnicas estructuradas de reconocimiento basadas en deep learning que dan uso de las mediciones del sistema global de navegación por satélite o GNSS integrada en los teléfonos inteligentes que recopila información como posición del satélite, pseudodistancia, desplazamiento Doppler, entre otros; aquí se enfocaron en cuatro diferentes espacios interiores poco profundos, semi exteriores y exteriores abiertos en donde se realizaron los cálculos inicialmente mediante redes neuronales convolucionales (CNN) y redes convolucionales de memoria a corto plazo (ConvLSTM), con lo cual se obtuvo una alta precisión con el método de CNN de 98.82% y luego se aumenta la robustez del algoritmo mediante ConvLSTM tratando las medidas de diferente manera y así obteniendo una precisión de 99.92%, con lo cual se llega a la conclusión que dichos algoritmos tienen gran potencial para ser aplicados a escenarios de la vida real.

## Referencias

- Kaggle. Google Smartphone Decimeter Challenge 2022. Recuperado el 20 de marzo de 2023 de: <https://www.kaggle.com/competitions/smartphone-decimeter-2022/overview>
- Kaggle. Android smartphones high accuracy GNSS datasets. Recuperado el 20 de marzo de 2023 de: <https://www.kaggle.com/datasets/google/android-smartphones-high-accuracy-datasets?select=ION+GNSS+2020+Android+Raw+GNSS+Measurement+Datasets+for+Precise+Positioning.pdf>
- Developers.(2019). Mediciones GNSS sin procesar. Recuperado el 20 de marzo de 2023 de: <https://developer.android.com/guide/topics/sensors/gnss?hl=es-419>
- Z. Dai, C. Zhai, F. Li, W. Chen, X. Zhu and Y. Feng, "Deep-Learning-Based Scenario Recognition With GNSS Measurements on Smartphones," in IEEE Sensors Journal, vol. 23, no. 4, pp. 3776-3786, 15 Feb.15, 2023, doi: 10.1109/JSEN.2022.3230213.<https://ieeexplore.ieee.org/abstract/document/9997533>